Actividad Clase 13: Regresión lineal, múltiple y logística

Minería de Datos · Departamento de Estadística, Universidad Nacional de Colombia, Sede Bogotá

David Márquez

19 de octubre de 2026

Contents

Datos **2**

Ejercicio 1: Regresión simple **3**

Ejercicio 2: Regresión múltiple **5**

Ejercicio 3: Variable categórica **7**

Ejercicio 4: Regresión logística **11**

Ejercicio 5: Diagnóstico y comunicación **15**

Gráficos de diagnóstico 15

Pruebas formales 17

Observaciones influyentes 18

Evaluación de los supuestos 19

Conclusión para el informe de negocio 19

Anexo: comparación con el proceso generador **19**

Información de la sesión **20**

```r
library(car)        # VIF, Anova tipo II, ncvTest, crPlots, outlierTest
library(lmtest)     # bptest, resettest, dwtest, coeftest
library(sandwich)   # errores estándar robustos (HC3)
library(pROC)       # curva ROC y AUC
library(ggplot2)    # gráficos
library(knitr)      # tablas

verde <- "#1b4d2e"
theme_set(theme_minimal(base_size = 12))
```

```r
# Funciones auxiliares para formatear números en el texto
f   <- function(x, d = 2) formatC(x, format = "f", digits = d)
pct <- function(x, d = 1) paste0(formatC(100 * x, format = "f", digits = d), "%")
fp  <- function(p) ifelse(p < 0.001, "< 0.001", paste("=", formatC(p, format = "f", digits = 3)))
fpt <- function(p) ifelse(p < 0.001, "< 0.001", formatC(p, format = "f", digits = 3))

# Tabla de coeficientes con IC al 95% y valor p formateado
tabla_coef <- function(m) {
  ci <- confint(m)
  data.frame(Estimación = coef(m), `IC 2.5%` = ci[, 1], `IC 97.5%` = ci[, 2],
             `Valor p` = fpt(summary(m)$coefficients[, 4]), check.names = FALSE)
}
```

Datos

Se usan los datos simulados del enunciado: 120 registros mensuales de ventas con gasto en publicidad, precio, región y un indicador de promoción.

```r
set.seed(42)
n <- 120
ventas <- data.frame(
  mes        = rep(1:12, times = 10),
  publicidad = round(runif(n, min = 2.0, max = 4.5), 1),
  precio     = round(runif(n, min = 13.0, max = 15.5), 1),
  region     = sample(c("Norte", "Sur", "Este", "Oeste"), n, replace = TRUE),
  promo      = sample(c(0L, 1L), n, replace = TRUE)
)
ventas$ventas <- round(
  100 + 18 * ventas$publicidad - 5 * ventas$precio +
    rnorm(n, mean = 0, sd = 8)
)

str(ventas)
```

```
#> 'data.frame':    120 obs. of  6 variables:
#>  $ mes       : int  1 2 3 4 5 6 7 8 9 10 ...
#>  $ publicidad: num  4.3 4.3 2.7 4.1 3.6 3.3 3.8 2.3 3.6 3.8 ...
#>  $ precio    : num  13.9 14 14.4 14.5 14.8 14 15.3 15.4 13.6 14.8 ...
#>  $ region    : chr  "Norte" "Este" "Este" "Sur" ...
#>  $ promo     : int  0 0 0 1 0 1 1 1 0 1 ...
#>  $ ventas    : num  102 115 87 111 80 106 100 64 102 87 ...
```

```r
summary(ventas[, c("publicidad", "precio", "ventas")])
```

```
#>    publicidad        precio          ventas     
#>  Min.   :2.000   Min.   :13.00   Min.   : 58.00  
#>  1st Qu.:2.700   1st Qu.:13.60   1st Qu.: 75.00  
#>  Median :3.350   Median :14.25   Median : 87.00  
#>  Mean   :3.316   Mean   :14.25   Mean   : 88.37  
#>  3rd Qu.:3.900   3rd Qu.:14.90   3rd Qu.:100.00  
#>  Max.   :4.500   Max.   :15.50   Max.   :125.00
```

```r
table(ventas$region)
```

```
#>
#>  Este Norte Oeste   Sur
#>    31    35    24    30
```

```r
table(ventas$promo)
```

```
#>
#>  0  1
#> 60 60
```

Correlaciones entre las variables numéricas:

```r
round(cor(ventas[, c("publicidad", "precio", "ventas")]), 3)
```

```
#>            publicidad precio ventas
#> publicidad      1.000 -0.007  0.859
#> precio         -0.007  1.000 -0.221
#> ventas          0.859 -0.221  1.000
```

Publicidad tiene una correlación fuerte y positiva con las ventas; precio, una correlación débil y negativa. Las dos variables predictoras prácticamente no están correladas entre sí, lo que anticipa que no habrá multicolinealidad en el modelo múltiple.

Ejercicio 1: Regresión simple

> Ajuste un modelo de regresión lineal simple que explique las ventas a partir del gasto en publicidad. Interprete el coeficiente de publicidad y el R^2. ¿El gasto en publicidad explica bien las ventas?

```r
mod1 <- lm(ventas ~ publicidad, data = ventas)
summary(mod1)
```

```
#>
#> Call:
#> lm(formula = ventas ~ publicidad, data = ventas)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -18.6056  -5.4383   0.3294   6.2130  20.1279
#>
#> Coefficients:
#>             Estimate Std. Error t value Pr(>|t|)
#> (Intercept)   26.468      3.485   7.595 7.98e-12 ***
#> publicidad    18.668      1.025  18.204  < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
```

```
#> Residual standard error: 8.362 on 118 degrees of freedom
#> Multiple R-squared:  0.7374, Adjusted R-squared:  0.7352
#> F-statistic: 331.4 on 1 and 118 DF,  p-value: < 2.2e-16
```

```
kable(tabla_coef(mod1), digits = 3, caption = "Coeficientes del modelo simple con IC al 95%")
```

Table 1: Coeficientes del modelo simple con IC al 95%

	Estimación	IC 2.5%	IC 97.5%	Valor p
(Intercept)	26.468	19.566	33.369	< 0.001
publicidad	18.668	16.637	20.698	< 0.001

```
ggplot(ventas, aes(publicidad, ventas)) +
  geom_point(alpha = 0.6, color = "grey30") +
  geom_smooth(method = "lm", formula = y ~ x, color = verde, fill = verde, alpha = 0.15) +
  labs(x = "Gasto en publicidad", y = "Ventas",
       title = sprintf("Ventas = %.2f + %.2f · publicidad   (R² = %.3f)",
                       b1[1], b1[2], r2_1))
```

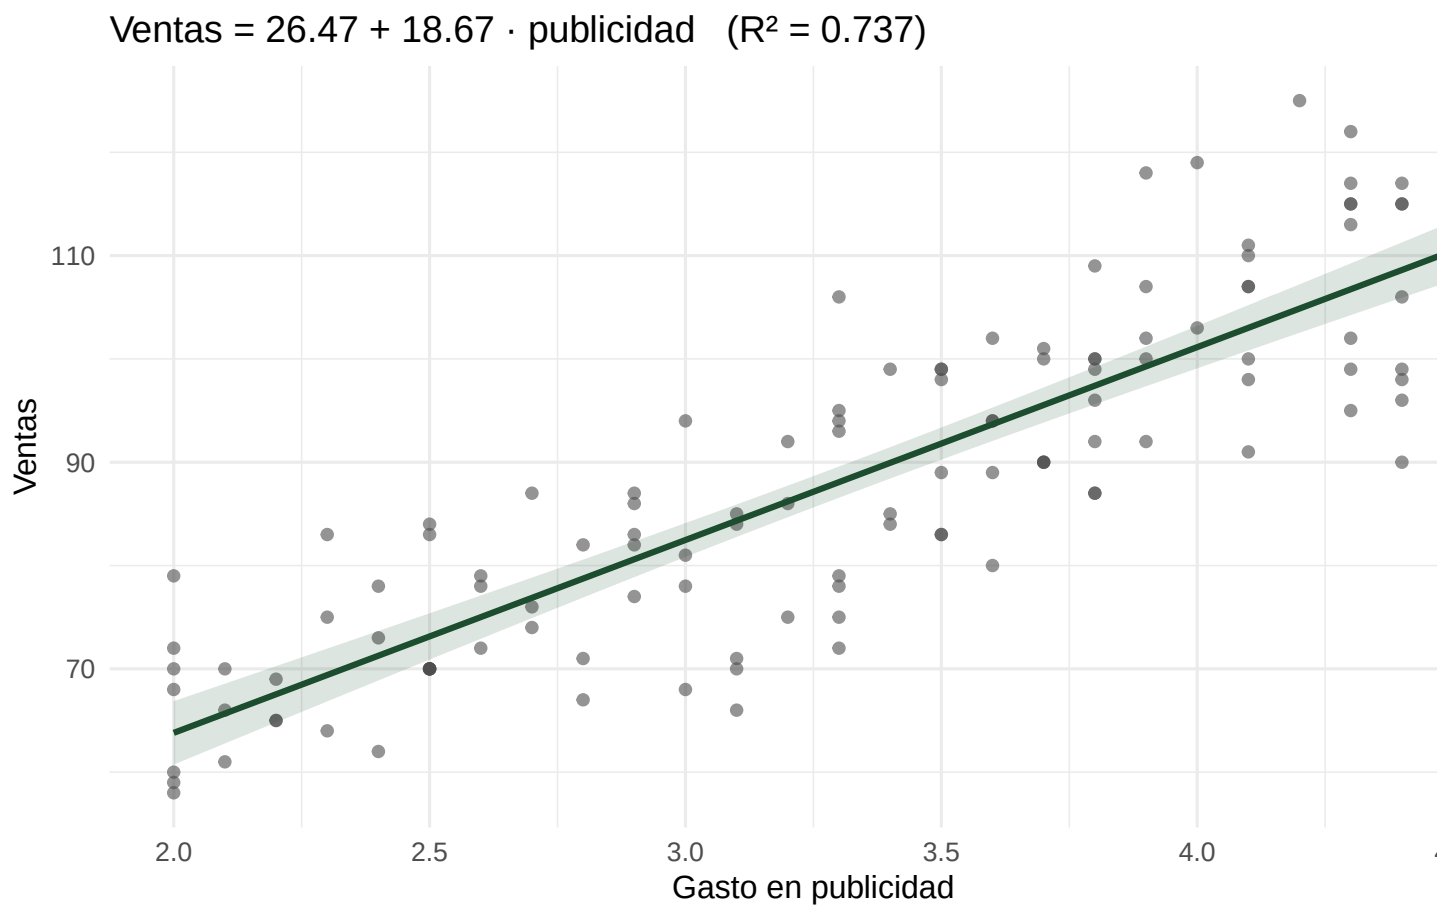


Figure 1: Ventas frente a gasto en publicidad con la recta MCO y su banda de confianza al 95%.

Interpretación

- **Coeficiente de publicidad ($\hat{\beta}_1 = 18.67$).** Por cada unidad adicional de gasto en publicidad, las ventas aumentan en promedio 18.67 unidades (IC 95%: 16.64 a 20.70). El efecto es altamente significativo (t = 18.20, p < 0.001).
- **Intercepto ($\hat{\beta}_0 = 26.47$).** Sería la venta esperada con publicidad igual a cero. Como el gasto observado va de 2.0 a 4.5, ese valor es una extrapolación y no tiene interpretación práctica.
- **$R^2 = 0.737$.** El gasto en publicidad explica el 73.7% de la variabilidad de las ventas. El error estándar residual es 8.36 unidades: es el error típico de una predicción.

¿Explica bien las ventas? Sí. La relación es fuerte (r = 0.859), positiva y estadísticamente significativa, y un solo predictor explica casi tres cuartas partes de la variación. Aun así, queda un 26.3% sin explicar, lo que sugiere que hay otros factores, como el precio, que vale la pena incorporar.

Ejercicio 2: Regresión múltiple

> Ajuste un modelo de regresión lineal múltiple con publicidad y precio como predictores. Compare el R^2 ajustado con el del ejercicio anterior. ¿Cuál variable aporta más a explicar las ventas?

```
mod2 <- lm(ventas ~ publicidad + precio, data = ventas)
summary(mod2)
```

```
#>
#> Call:
#> lm(formula = ventas ~ publicidad + precio, data = ventas)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -21.0588  -5.6298   0.1359   5.5561  19.4031
#>
#> Coefficients:
#>             Estimate Std. Error t value Pr(>|t|)
#> (Intercept)  96.3860    14.3346   6.724 6.83e-10 ***
#> publicidad   18.6337     0.9348  19.934  < 2e-16 ***
#> precio       -4.8972     0.9791  -5.002 2.02e-06 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 7.622 on 117 degrees of freedom
#> Multiple R-squared:  0.7837, Adjusted R-squared:   0.78
#> F-statistic: 211.9 on 2 and 117 DF,  p-value: < 2.2e-16
```

```
kable(tabla_coef(mod2), digits = 3, caption = "Coeficientes del modelo múltiple con IC al 95%")
```

Table 2: Coeficientes del modelo múltiple con IC al 95%

	Estimación	IC 2.5%	IC 97.5%	Valor p
(Intercept)	96.386	67.997	124.775	< 0.001
publicidad	18.634	16.782	20.485	< 0.001
precio	-4.897	-6.836	-2.958	< 0.001

Multicolinealidad (VIF):

```r
vif(mod2)
```

```
#> publicidad     precio
#>   1.000053   1.000053
```

Comparación con el modelo simple:

```r
resumen_modelo <- function(m, nombre) {
  s <- summary(m)
  data.frame(Modelo = nombre, Predictores = length(coef(m)) - 1,
             R2 = s$r.squared, R2_ajustado = s$adj.r.squared,
             RSE = s$sigma, AIC = AIC(m), BIC = BIC(m))
}
comp12 <- rbind(resumen_modelo(mod1, "M1: publicidad"),
                resumen_modelo(mod2, "M2: publicidad + precio"))
kable(comp12, digits = 4, row.names = FALSE)
```

Modelo	Predictores	R2	R2_ajustado	RSE	AIC	BIC
M1: publicidad	1	0.7374	0.7352	8.3624	854.2267	862.5892
M2: publicidad + precio	2	0.7837	0.7800	7.6225	832.9719	844.1219

```r
# Prueba F parcial: ¿precio mejora significativamente el modelo?
anova(mod1, mod2)
```

```
#> Analysis of Variance Table
#>
#> Model 1: ventas ~ publicidad
#> Model 2: ventas ~ publicidad + precio
#>   Res.Df    RSS Df Sum of Sq     F    Pr(>F)
#> 1    118 8251.7
#> 2    117 6798.0  1    1453.7 25.02 2.017e-06 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

¿Qué variable aporta más? Los coeficientes crudos no son comparables porque cada variable tiene su propia escala. Se comparan entonces los coeficientes estandarizados, la suma de cuadrados tipo II (lo que cada variable aporta controlando por la otra) y el R^2 parcial.

```r
# Coeficientes estandarizados: cambio en DE de ventas por 1 DE del predictor
mod2_std <- lm(scale(ventas) ~ scale(publicidad) + scale(precio), data = ventas)
beta_std <- coef(mod2_std)[-1]

# Suma de cuadrados tipo II y R² parcial
a2   <- Anova(mod2, type = 2)
sce  <- a2["Residuals", "Sum Sq"]
ss   <- a2[c("publicidad", "precio"), "Sum Sq"]
importancia <- data.frame(
  Variable          = c("publicidad", "precio"),
  `Beta estandarizado` = beta_std,
  `t`               = summary(mod2)$coefficients[-1, 3],
```

```
  `SC tipo II`      = ss,
  `R² parcial`      = ss / (ss + sce),
  check.names = FALSE
)
kable(importancia, digits = 3, row.names = FALSE)
```

Variable	Beta estandarizado	t	SC tipo II	R^2 parcial
publicidad	0.857	19.934	23088.409	0.773
precio	-0.215	-5.002	1453.691	0.176

Interpretación

- **Publicidad ($\hat{\beta}_1$ = 18.63).** Manteniendo el precio constante, cada unidad adicional de publicidad se asocia con 18.63 unidades más de ventas (IC 95%: 16.78 a 20.48). El coeficiente casi no cambia respecto al modelo simple (18.67) porque publicidad y precio son prácticamente independientes (VIF = 1.000).
- **Precio ($\hat{\beta}_2$ = -4.90).** Manteniendo la publicidad constante, cada unidad adicional de precio se asocia con una caída promedio de 4.90 unidades en ventas (IC 95%: -6.84 a -2.96, $p < 0.001$).
- **R^2 ajustado.** Pasa de 0.7352 (M1) a 0.7800 (M2), una mejora de 4.5 puntos porcentuales. El RSE baja de 8.36 a 7.62, y la prueba F parcial confirma que agregar precio mejora el ajuste de forma significativa ($F = 25.02$, $p < 0.001$). AIC y BIC también favorecen a M2.
- **¿Cuál aporta más? La publicidad**, por amplio margen. Su coeficiente estandarizado es 0.857 frente a -0.215 del precio: una desviación estándar más de publicidad mueve las ventas 4.0 veces más que una desviación estándar de precio. Controlando por la otra variable, la publicidad explica el 77.3% de la variación residual y el precio solo el 17.6%. El precio aporta información real y significativa, pero complementaria.

Ejercicio 3: Variable categórica

> Incluya la variable `region` como predictor en el modelo múltiple. Codifíquela correctamente como variable dummy. ¿Existe diferencia significativa en ventas entre regiones? Interprete los coeficientes.

`region` tiene $k = 4$ categorías, así que entra al modelo como $k - 1 = 3$ variables indicadoras. Se convierte a `factor` y se fija **Norte** como categoría de referencia (por defecto R tomaría la primera en orden alfabético, *Este*).

```
ventas$region <- factor(ventas$region, levels = c("Norte", "Sur", "Este", "Oeste"))
contrasts(ventas$region)   # matriz de codificación dummy (tratamiento)
```

```
#>       Sur Este Oeste
#> Norte   0    0     0
#> Sur     1    0     0
#> Este    0    1     0
#> Oeste   0    0     1
```

```
# Las 3 columnas dummy que R construye internamente
head(model.matrix(~ publicidad + precio + region, data = ventas))
```

```
#>   (Intercept) publicidad precio regionSur regionEste regionOeste
#> 1           1        4.3   13.9         0          0           0
#> 2           1        4.3   14.0         0          1           0
#> 3           1        2.7   14.4         0          1           0
#> 4           1        4.1   14.5         1          0           0
#> 5           1        3.6   14.8         0          0           1
#> 6           1        3.3   14.0         0          0           1
```

```
mod3 <- lm(ventas ~ publicidad + precio + region, data = ventas)
summary(mod3)
```

```
#>
#> Call:
#> lm(formula = ventas ~ publicidad + precio + region, data = ventas)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -18.8491  -5.6743   0.2233   5.3638  18.9536
#>
#> Coefficients:
#>             Estimate Std. Error t value Pr(>|t|)
#> (Intercept)  99.3859    14.5456   6.833 4.32e-10 ***
#> publicidad   18.6227     0.9447  19.713  < 2e-16 ***
#> precio       -5.0908     0.9851  -5.168 1.02e-06 ***
#> regionSur    -0.3343     1.9181  -0.174    0.862
#> regionEste    1.4898     1.8793   0.793    0.430
#> regionOeste  -2.5226     2.0159  -1.251    0.213
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 7.598 on 114 degrees of freedom
#> Multiple R-squared:  0.7906, Adjusted R-squared:  0.7814
#> F-statistic: 86.09 on 5 and 114 DF,  p-value: < 2.2e-16
```

```
kable(tabla_coef(mod3), digits = 3, caption = "Coeficientes del modelo con región (referencia: Norte)")
```

Table 5: Coeficientes del modelo con región (referencia: Norte)

	Estimación	IC 2.5%	IC 97.5%	Valor p
(Intercept)	99.386	70.571	128.201	< 0.001
publicidad	18.623	16.751	20.494	< 0.001
precio	-5.091	-7.042	-3.139	< 0.001
regionSur	-0.334	-4.134	3.465	0.862
regionEste	1.490	-2.233	5.213	0.430
regionOeste	-2.523	-6.516	1.471	0.213

Prueba global de región. Las pruebas t individuales solo comparan cada región contra Norte. Para saber si la región importa en conjunto se usa la prueba F parcial, que compara M2 con M3 (equivalente a la prueba tipo II de `Anova`):

```r
anova(mod2, mod3)
```

```
#> Analysis of Variance Table
#>
#> Model 1: ventas ~ publicidad + precio
#> Model 2: ventas ~ publicidad + precio + region
#>   Res.Df    RSS Df Sum of Sq      F Pr(>F)
#> 1    117 6798.0
#> 2    114 6580.3  3    217.65 1.2569 0.2926
```

```r
Anova(mod3, type = 2)
```

```
#> Anova Table (Type II tests)
#>
#> Response: ventas
#>             Sum Sq  Df  F value    Pr(>F)
#> publicidad 22430.3   1 388.5908 < 2.2e-16 ***
#> precio      1541.5   1  26.7058  1.02e-06 ***
#> region       217.6   3   1.2569    0.2926
#> Residuals   6580.3 114
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
kable(rbind(resumen_modelo(mod2, "M2: publicidad + precio"),
            resumen_modelo(mod3, "M3: publicidad + precio + región")),
      digits = 4, row.names = FALSE)
```

Modelo	Predictores	R2	R2_ajustado	RSE	AIC	BIC
M2: publicidad + precio	2	0.7837	0.7800	7.6225	832.9719	844.1219
M3: publicidad + precio + región	5	0.7906	0.7814	7.5975	835.0671	854.5796

```r
ventas$res_m2 <- residuals(mod2)
ggplot(ventas, aes(region, res_m2)) +
  geom_hline(yintercept = 0, linetype = 2, color = "grey50") +
  geom_boxplot(fill = verde, alpha = 0.15, outlier.shape = NA, color = verde) +
  geom_jitter(width = 0.15, alpha = 0.5, color = "grey30") +
  labs(x = "Región", y = "Residuo de M2")
```

Interpretación de los coeficientes (todos manteniendo constantes publicidad y precio, y comparados con Norte):

- **regionSur = -0.33:** en promedio, Sur vende 0.33 unidades menos que Norte (p = 0.862).
- **regionEste = 1.49:** Este vende 1.49 unidades más que Norte (p = 0.430).
- **regionOeste = -2.52:** Oeste vende 2.52 unidades menos que Norte (p = 0.213).
- El intercepto ahora corresponde a la región Norte, y los efectos de publicidad (18.62) y precio (-5.09) prácticamente no cambian al agregar la región.

¿Hay diferencia significativa entre regiones? No. Ninguna diferencia individual es significativa, y la prueba F conjunta tampoco lo es ($F = 1.26$ con 3 y 114 gl, $p = 0.293$). Todas las diferencias son menores de 3 unidades, pequeñas frente al error típico de 7.60. El R^2 ajustado sube de forma marginal (0.7800 → 0.7814), pero el BIC empeora. Por parsimonia se prefiere M2 sin región: una vez que se controla por publicidad y precio, la región no ayuda a explicar las ventas.

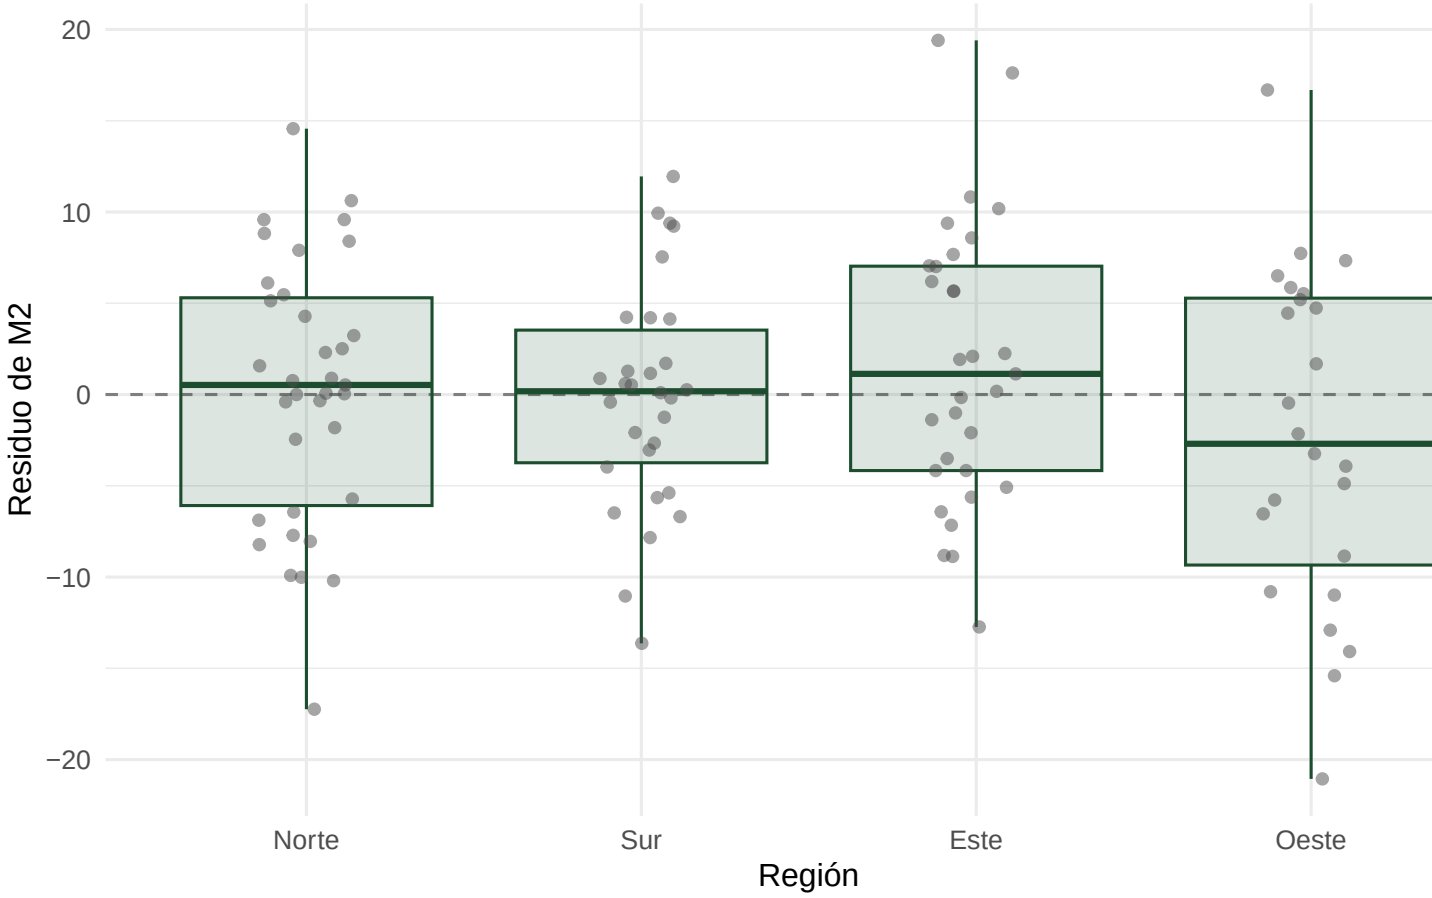


Figure 2: Residuos del modelo M2 (publicidad + precio) por región: lo que la región podría explicar después de controlar por publicidad y precio.

Ejercicio 4: Regresión logística

> Use la variable `promo` (0 = sin promoción, 1 = con promoción) como variable dependiente. Ajuste un modelo logístico con publicidad y precio como predictores. Reporte los odds ratios e interprete el efecto del precio sobre la probabilidad de aplicar una promoción.

```
mod4 <- glm(promo ~ publicidad + precio, data = ventas,
            family = binomial(link = "logit"))
summary(mod4)
```

```
#>
#> Call:
#> glm(formula = promo ~ publicidad + precio, family = binomial(link = "logit"),
#>     data = ventas)
#>
#> Coefficients:
#>             Estimate Std. Error z value Pr(>|z|)
#> (Intercept)  5.37465    3.81831   1.408    0.159
#> publicidad   0.05533    0.24751   0.224    0.823
#> precio      -0.38993    0.26113  -1.493    0.135
#>
#> (Dispersion parameter for binomial family taken to be 1)
#>
#>     Null deviance: 166.36  on 119  degrees of freedom
#> Residual deviance: 164.03  on 117  degrees of freedom
#> AIC: 170.03
#>
#> Number of Fisher Scoring iterations: 4
```

Odds ratios con IC al 95% (perfil de verosimilitud):

```
ic_or <- exp(confint(mod4))
tab4 <- data.frame(
  `B (logit)`  = coef(mod4),
  OR           = exp(coef(mod4)),
  `IC 2.5%`    = ic_or[, 1],
  `IC 97.5%`   = ic_or[, 2],
  `Valor p`    = summary(mod4)$coefficients[, 4],
  check.names = FALSE
)
tab4_vista <- tab4[-1, ]   # el intercepto (odds con publicidad = precio = 0) no es interpretable
tab4_vista$`Valor p` <- fpt(tab4_vista$`Valor p`)
kable(tab4_vista, digits = 3)
```

	B (logit)	OR	IC 2.5%	IC 97.5%	Valor p
publicidad	0.055	1.057	0.649	1.722	0.823
precio	-0.390	0.677	0.402	1.124	0.135

Significancia global (razón de verosimilitudes contra el modelo nulo):

```r
mod4_nulo <- glm(promo ~ 1, data = ventas, family = binomial)
anova(mod4_nulo, mod4, test = "Chisq")
```

```
#> Analysis of Deviance Table
#>
#> Model 1: promo ~ 1
#> Model 2: promo ~ publicidad + precio
#>   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
#> 1       119     166.35
#> 2       117     164.03  2   2.3205   0.3134
```

Efecto del precio en la escala de probabilidad. El efecto marginal promedio es $\frac{\partial P}{\partial x} = \hat{\beta}\, p(1-p)$, promediado sobre las observaciones:

```r
p_hat <- fitted(mod4)
efecto_marginal <- coef(mod4)[-1] * mean(p_hat * (1 - p_hat))
round(efecto_marginal, 4)
```

```
#> publicidad     precio
#>     0.0136    -0.0956
```

```r
grid <- data.frame(precio = seq(13, 15.5, by = 0.05),
                   publicidad = mean(ventas$publicidad))
pr <- predict(mod4, newdata = grid, type = "link", se.fit = TRUE)
grid$p   <- plogis(pr$fit)
grid$lwr <- plogis(pr$fit - 1.96 * pr$se.fit)
grid$upr <- plogis(pr$fit + 1.96 * pr$se.fit)

ggplot(grid, aes(precio, p)) +
  geom_ribbon(aes(ymin = lwr, ymax = upr), fill = verde, alpha = 0.15) +
  geom_line(color = verde, linewidth = 1) +
  geom_jitter(data = ventas, aes(precio, promo), width = 0, height = 0.03,
              alpha = 0.4, color = "grey30") +
  scale_y_continuous(limits = c(-0.05, 1.05), breaks = seq(0, 1, 0.25)) +
  labs(x = "Precio", y = "P(promo = 1)")
```

Capacidad de discriminación:

```r
roc4 <- roc(ventas$promo, p_hat, quiet = TRUE)
plot(roc4, col = verde, lwd = 2,
     main = paste("Curva ROC | AUC =", round(auc(roc4), 3)))
abline(a = 1, b = -1, lty = 2, col = "#94a3b8")
```

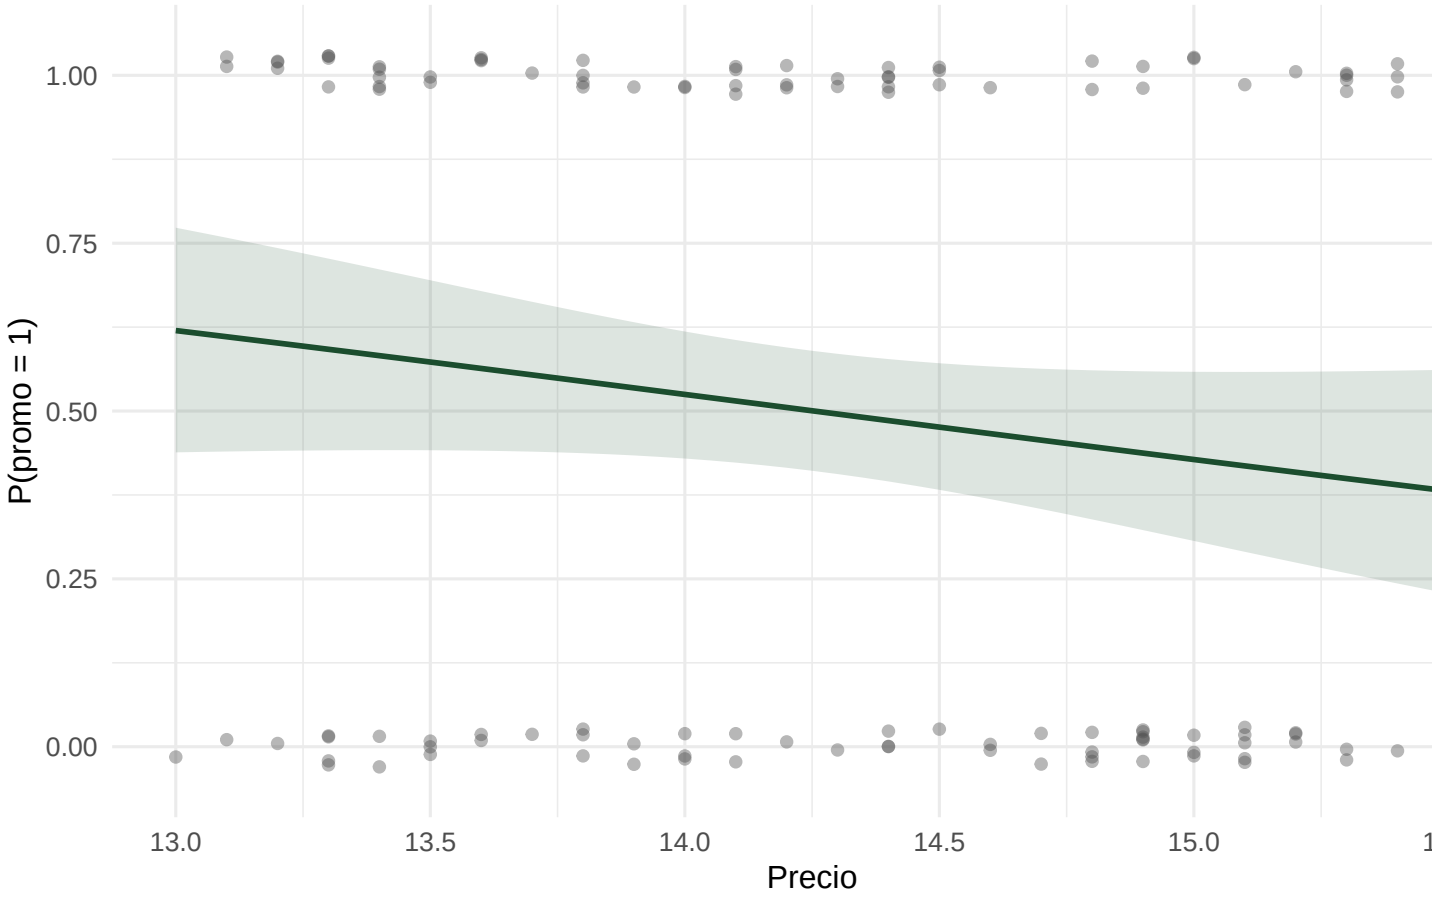
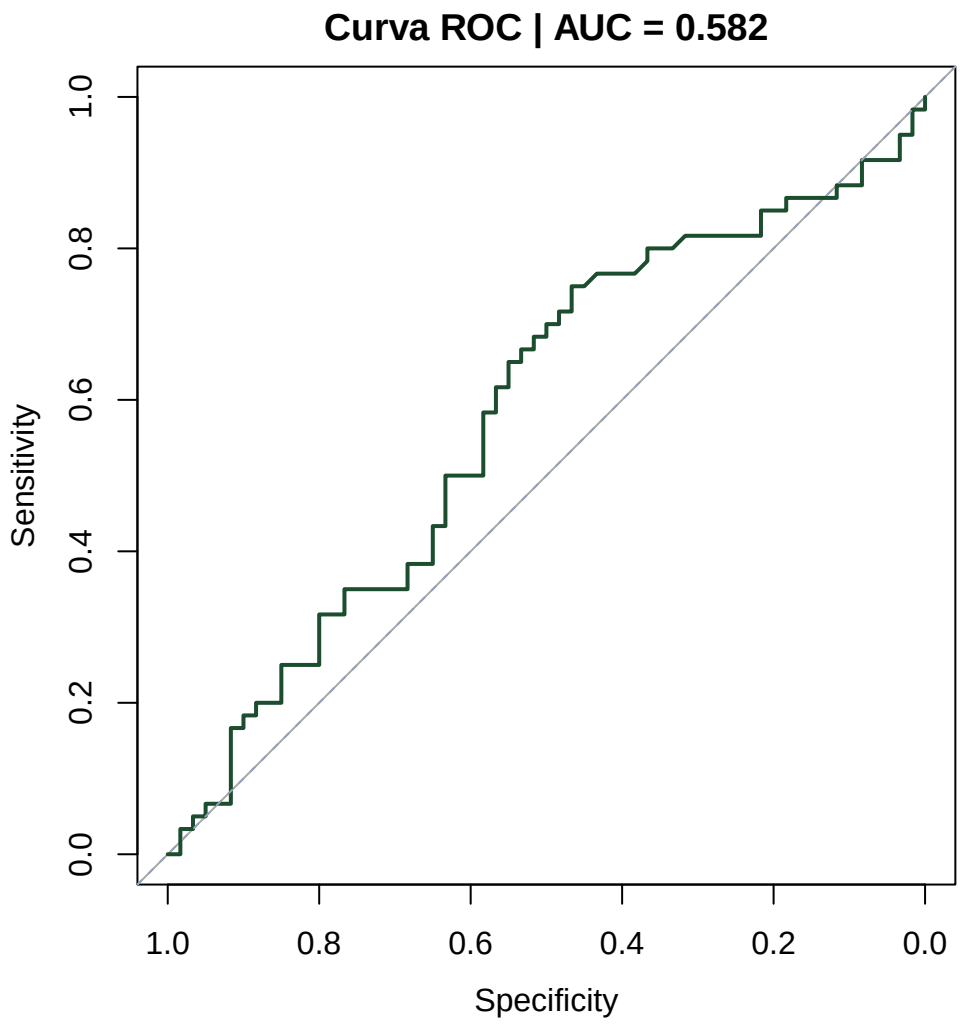


Figure 3: Probabilidad estimada de promoción según el precio, con la publicidad fija en su media. Banda: IC 95%. Puntos: observaciones (0/1) con dispersión vertical.




```
ci.auc(roc4)
```

```
#> 95% CI: 0.4785-0.6857 (DeLong)
```

Interpretación

- **Odds ratio del precio = 0.677.** Manteniendo constante la publicidad, cada unidad adicional de precio multiplica los odds de aplicar una promoción por 0.677, es decir, los **reduce en un 32%**. En la escala de probabilidad equivale a unos 9.6 puntos porcentuales menos de probabilidad de promoción por unidad de precio (efecto marginal promedio).
- **Pero el efecto no es estadísticamente significativo.** El IC 95% del OR va de 0.402 a 1.124 e **incluye el 1**, y p = 0.135. Los datos no permiten afirmar que el precio cambie la probabilidad de aplicar una promoción: el signo negativo bien puede deberse al azar.
- **Publicidad:** OR = 1.057 (IC 95%: 0.649 a 1.722, p = 0.823). Tampoco tiene un efecto apreciable.
- **Modelo en conjunto:** la prueba de razón de verosimilitudes contra el modelo nulo no es significativa (X2 = 2.32, 2 gl, p = 0.313), y el AUC = 0.582 (IC 95%: 0.479 a 0.686) no se distingue de 0.5, que es la discriminación de una moneda al aire.

Conclusión: ni el precio ni la publicidad permiten anticipar si se aplica una promoción. El resultado es coherente con cómo se generaron los datos: `promo` se asignó con `sample()`, independiente de las demás

variables. Además, aunque hubiera asociación, el modelo solo mediría eso; la dirección causal (si el precio lleva a promocionar o si la promoción se refleja en el precio) no se puede establecer con estos datos.

Ejercicio 5: Diagnóstico y comunicación

> Para el modelo múltiple del ejercicio 2, genere los gráficos de diagnóstico (residuales vs. ajustados, Q-Q de residuales, escala-localización). Identifique si se cumplen los supuestos de linealidad, homocedasticidad y normalidad. Redacte una conclusión de dos párrafos como si fuera para un informe de negocio.

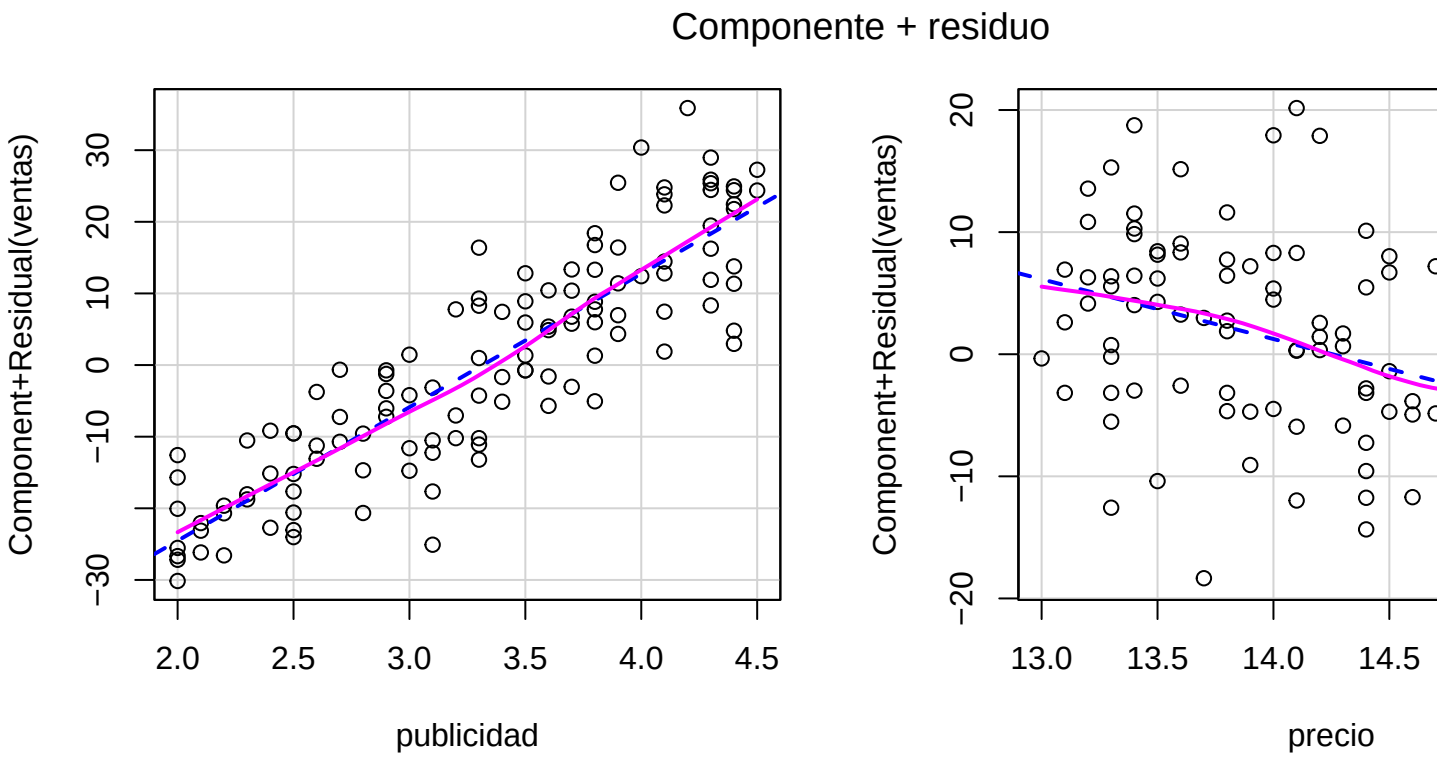
Gráficos de diagnóstico

```
par(mfrow = c(2, 2), mar = c(4.5, 4.5, 2.5, 1))
plot(mod2, which = c(1, 2, 3, 5), col = adjustcolor("grey30", 0.6), pch = 19)
```

```
par(mfrow = c(1, 1))
```

Gráficos de componente + residuo, para revisar la linealidad de cada predictor por separado:

```
crPlots(mod2, layout = c(1, 2), main = "Componente + residuo")
```



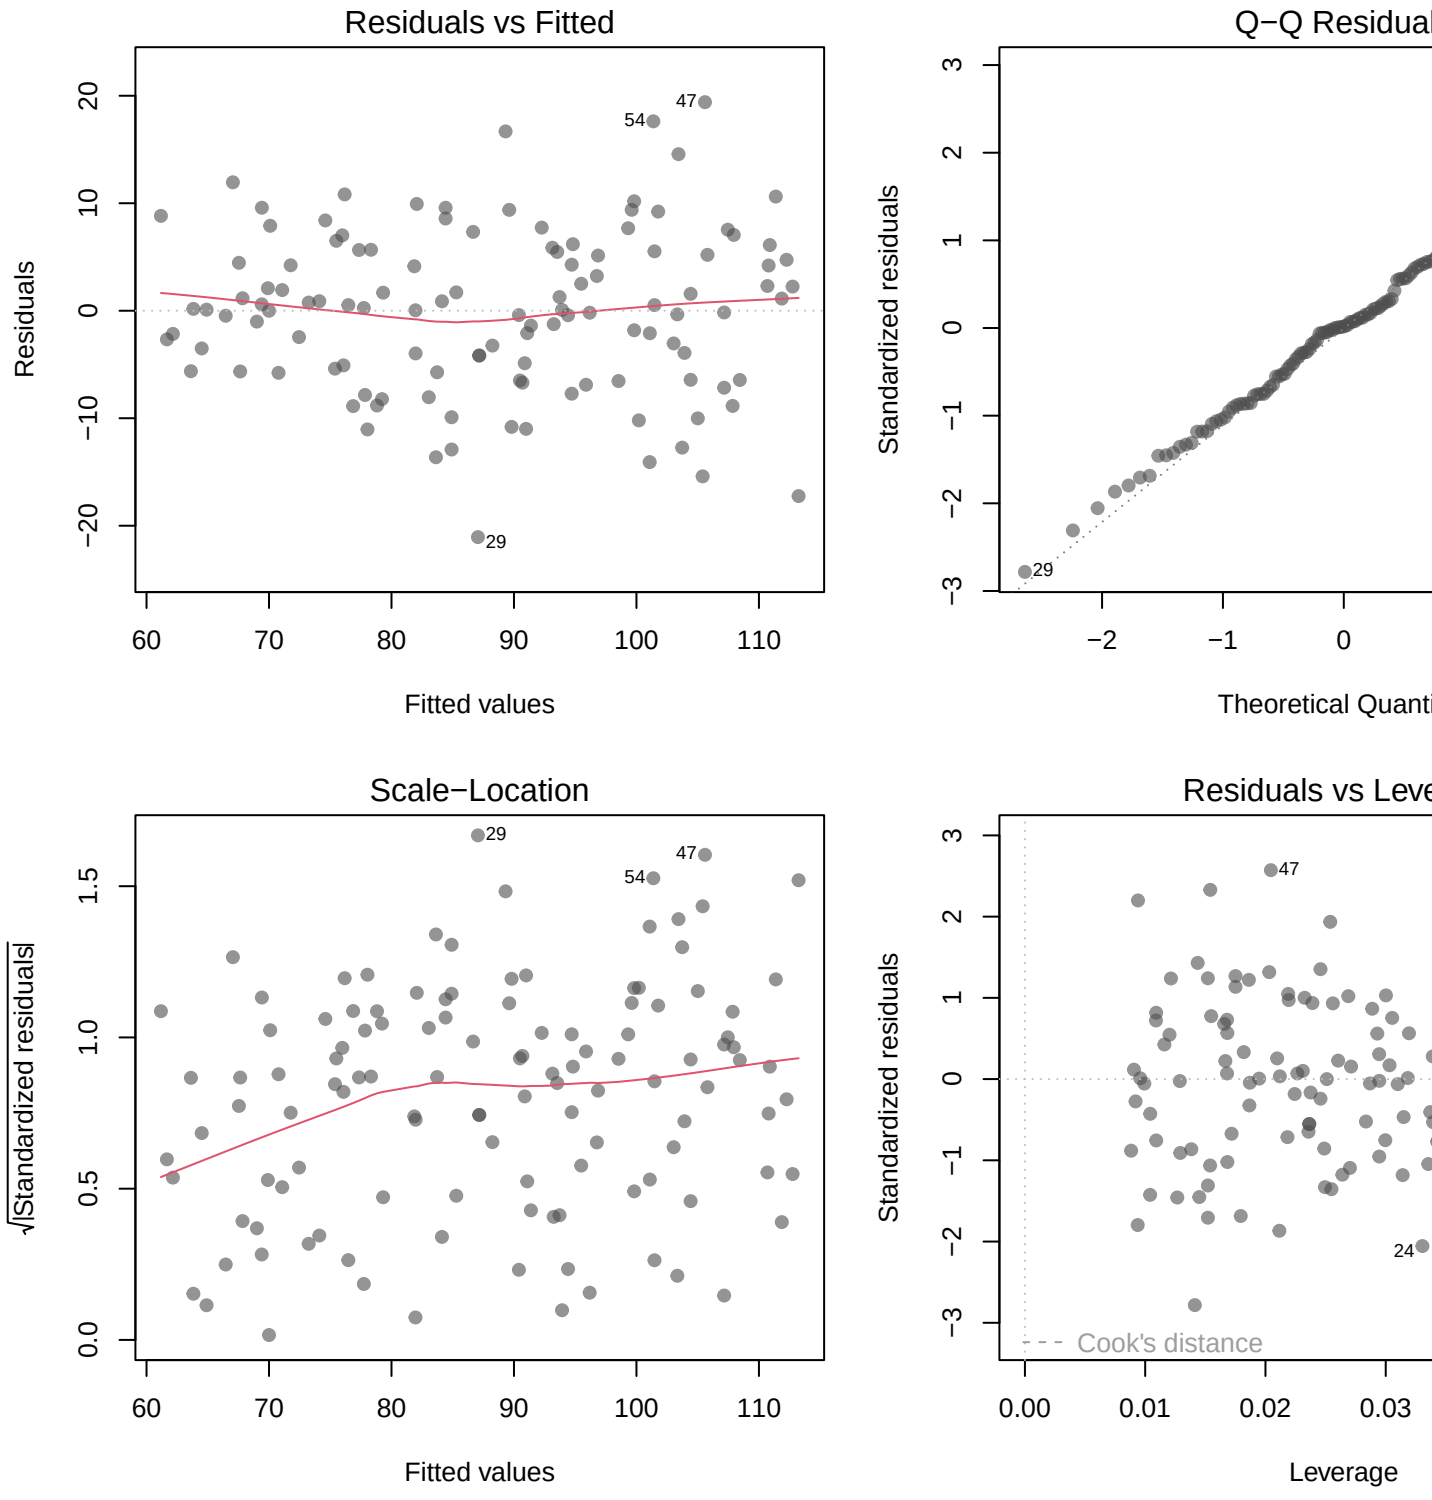


Figure 4: Diagnóstico del modelo M2: residuos vs. ajustados, Q-Q normal, escala-localización y residuos vs. apalancamiento (con contornos de Cook).

Pruebas formales

```
reset <- resettest(mod2, power = 2:3)        # linealidad (Ramsey RESET)
bp    <- bptest(mod2)                        # homocedasticidad vs. predictores
ncv   <- ncvTest(mod2)                       # homocedasticidad vs. valores ajustados
sw    <- shapiro.test(residuals(mod2))       # normalidad
dw    <- dwtest(mod2)                        # independencia (autocorrelación)

pruebas <- data.frame(
  Supuesto    = c("Linealidad", "Homocedasticidad", "Homocedasticidad",
                  "Normalidad", "Independencia"),
  Prueba      = c("RESET de Ramsey", "Breusch-Pagan (studentizada)",
                  "Score test sobre ajustados (ncvTest)", "Shapiro-Wilk",
                  "Durbin-Watson"),
  Estadístico = c(reset$statistic, bp$statistic, ncv$ChiSquare,
                  sw$statistic, dw$statistic),
  `Valor p`   = c(reset$p.value, bp$p.value, ncv$p, sw$p.value, dw$p.value),
  check.names = FALSE
)
pruebas$Decisión <- ifelse(pruebas$`Valor p` < 0.05,
                           "Se rechaza H0 (  = 5%)", "No se rechaza H0")
kable(pruebas, digits = 3, row.names = FALSE)
```

Supuesto	Prueba	Estadístico	Valor p	Decisión
Linealidad	RESET de Ramsey	0.491	0.613	No se rechaza H0
Homocedasticidad	Breusch-Pagan (studentizada)	5.051	0.080	No se rechaza H0
Homocedasticidad	Score test sobre ajustados (ncvTest)	4.737	0.030	Se rechaza H0 (= 5%)
Normalidad	Shapiro-Wilk	0.995	0.945	No se rechaza H0
Independencia	Durbin-Watson	2.091	0.685	No se rechaza H0

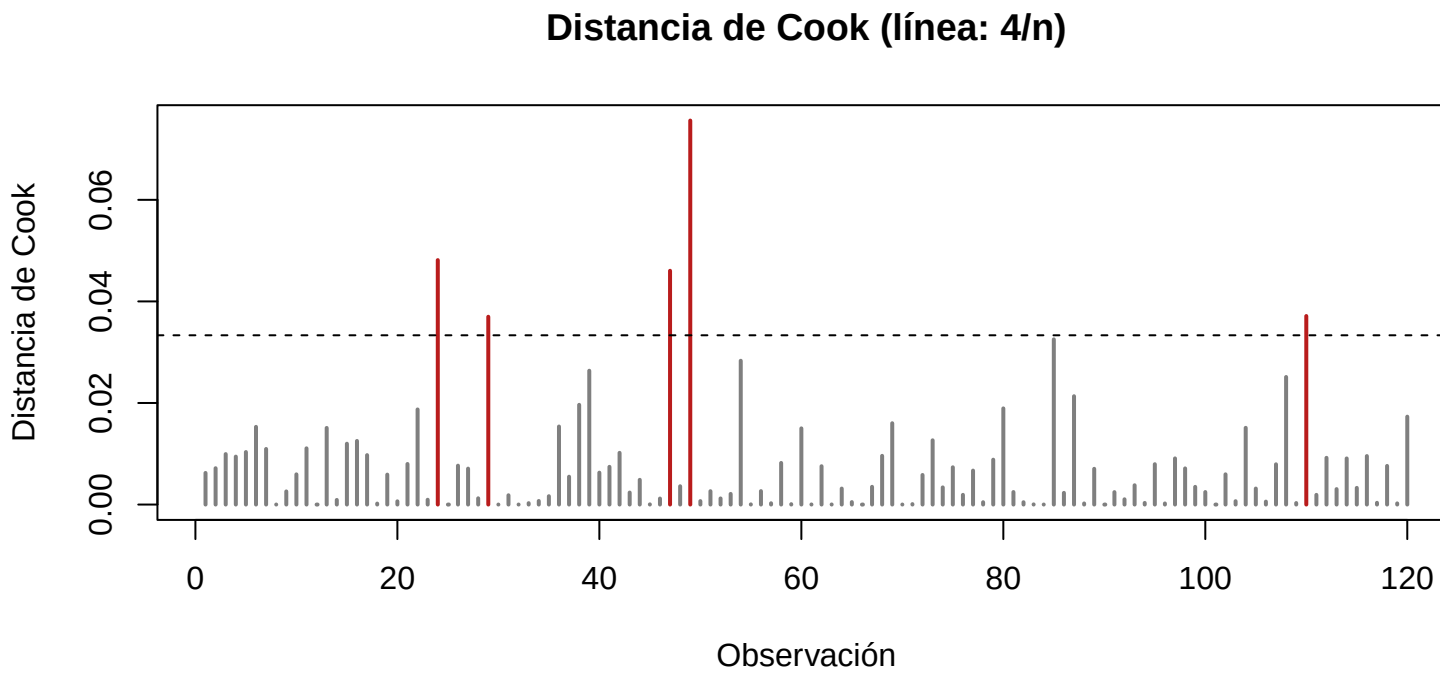
Como una de las dos pruebas de homocedasticidad sale significativa, se comparan los errores estándar clásicos con los robustos a heterocedasticidad (HC3):

```
ct_clasico <- coeftest(mod2)
ct_hc3     <- coeftest(mod2, vcov. = vcovHC(mod2, type = "HC3"))
kable(data.frame(
  Estimación     = ct_clasico[, 1],
  `EE clásico`   = ct_clasico[, 2],
  `EE HC3`       = ct_hc3[, 2],
  `p clásico`    = fpt(ct_clasico[, 4]),
  `p HC3`        = fpt(ct_hc3[, 4]),
  check.names = FALSE
), digits = 3)
```

	Estimación	EE clásico	EE HC3	p clásico	p HC3
(Intercept)	96.386	14.335	13.190	< 0.001	< 0.001
publicidad	18.634	0.935	0.893	< 0.001	< 0.001
precio	-4.897	0.979	0.911	< 0.001	< 0.001

Observaciones influyentes

```
cook   <- cooks.distance(mod2)
umbral <- 4 / nrow(ventas)
plot(cook, type = "h", col = ifelse(cook > umbral, "#b91c1c", "grey50"), lwd = 2,
     xlab = "Observación", ylab = "Distancia de Cook",
     main = "Distancia de Cook (línea: 4/n)")
abline(h = umbral, lty = 2)
```




```
which(cook > umbral)
```

```
#>  24  29  47  49 110
#>  24  29  47  49 110
```

```
outlierTest(mod2)
```

```
#> No Studentized residuals with Bonferroni p < 0.05
#> Largest |rstudent|:
#>     rstudent unadjusted p-value Bonferroni p
#> 29 -2.867001          0.0049228      0.59074
```

```
# Sensibilidad: ¿cambian los coeficientes sin esas observaciones?
mod2_sin <- update(mod2, subset = cook <= umbral)
round(rbind(`Con todas` = coef(mod2), `Sin influyentes` = coef(mod2_sin)), 3)
```

```
#>                 (Intercept) publicidad precio
#> Con todas            96.386     18.634 -4.897
#> Sin influyentes      96.757     19.114 -5.021
```

Evaluación de los supuestos

- **Linealidad: se cumple.** En *Residuals vs Fitted* los residuos forman una nube aleatoria alrededor de cero, sin arco ni patrón, y la curva suavizada es casi horizontal. Los gráficos de componente + residuo muestran relaciones lineales para publicidad y para precio, y la prueba RESET no detecta términos no lineales omitidos ($p = 0.613$).
- **Homocedasticidad: se cumple de forma aproximada.** En *Scale-Location* la línea sube en el tramo de ventas predichas bajas (por debajo de unas 80 unidades) y luego se estabiliza. Es decir, la dispersión de los errores es algo menor cuando las ventas esperadas son bajas, sin llegar a formar un embudo marcado. La prueba de Breusch-Pagan no rechaza la varianza constante ($p = 0.080$), pero el *score test* sobre los valores ajustados sí la rechaza al 5% ($p = 0.030$). Es una evidencia mixta de heterocedasticidad leve. En la práctica no afecta las conclusiones: con errores estándar robustos HC3, publicidad y precio siguen siendo significativos ($p < 0.001$ y $p < 0.001$).
- **Normalidad: se cumple.** En el Q-Q los puntos siguen de cerca la diagonal, sin colas pesadas, y Shapiro-Wilk no rechaza la normalidad ($W = 0.995$, $p = 0.945$).
- **Independencia y puntos influyentes.** Durbin-Watson = 2.09 ($p = 0.685$) no indica autocorrelación. Ninguna observación tiene distancia de Cook mayor que 1 (máximo 0.076). Hay 5 puntos por encima de la señal de alerta 4/n, pero ninguno es atípico según la prueba de Bonferroni. Al excluirlos, los coeficientes cambian poco (publicidad de 18.63 a 19.11, precio de -4.90 a -5.02) y siguen dentro de sus intervalos de confianza.

Conclusión para el informe de negocio

El análisis de los 120 registros muestra que **la inversión en publicidad es el principal motor de las ventas**. Con el precio constante, cada unidad adicional de gasto publicitario se asocia con unas **18.6 unidades más de ventas** (entre 16.8 y 20.5 con 95% de confianza). El precio tiene un efecto contrario y más moderado: cada unidad de aumento en el precio se asocia con unas **4.9 unidades menos de ventas**. Juntas, estas dos palancas explican cerca del **78% de la variación de las ventas**, con un error típico de pronóstico de ± 7.6 unidades. En términos prácticos, subir el precio en una unidad puede compensarse, en volumen, con unas 0.26 unidades adicionales de inversión publicitaria. Esa compensación sirve para evaluar en conjunto la estrategia de precios y el presupuesto de mercadeo.

Las pruebas de validez respaldan estas cifras. La relación entre las variables es lineal, los errores se comportan como se espera y ningún registro aislado distorsiona los resultados. La única alerta, una leve variación en la dispersión de los errores, se revisó con un método robusto y no cambia ninguna conclusión. Se recomienda **priorizar la inversión publicitaria** y **evaluar cualquier alza de precio frente a la pérdida de volumen que implica**, con dos precauciones. Primero, el modelo mide asociación y no causalidad: antes de reasignar presupuestos grandes conviene confirmar el efecto con un piloto controlado. Segundo, las estimaciones solo son válidas dentro de los rangos observados (publicidad entre 2.0 y 4.5, precio entre 13.0 y 15.5). El 22% de la variación que queda sin explicar sugiere incorporar más adelante otras variables, como estacionalidad o acciones de la competencia.

Anexo: comparación con el proceso generador

Como los datos son simulados, se conoce el modelo verdadero: $\text{ventas} = 100 + 18\,\text{publicidad} - 5\,\text{precio} + \varepsilon$, con $\varepsilon \sim N(0, 8^2)$. `region` y `promo` se asignaron al azar.

```r
kable(data.frame(
  Parámetro  = c("Intercepto", "publicidad", "precio", "  (error)"),
  Verdadero  = c(100, 18, -5, 8),
  Estimado   = c(coef(mod2), summary(mod2)$sigma),
  `IC 2.5%`  = c(confint(mod2)[, 1], NA),
  `IC 97.5%` = c(confint(mod2)[, 2], NA),
  check.names = FALSE
), digits = 2, row.names = FALSE)
```

Parámetro	Verdadero	Estimado	IC 2.5%	IC 97.5%
Intercepto	100	96.39	68.00	124.77
publicidad	18	18.63	16.78	20.48
precio	-5	-4.90	-6.84	-2.96
(error)	8	7.62	NA	NA

Todos los intervalos de confianza contienen el valor verdadero. Los resultados nulos para región (ejercicio 3) y promoción (ejercicio 4) son los esperados, porque esas variables no intervienen en la generación de las ventas.

Información de la sesión

```r
sessionInfo()
```

```
#> R version 4.6.1 (2026-06-24 ucrt)
#> Platform: x86_64-w64-mingw32/x64
#> Running under: Windows 10 x64 (build 19045)
#>
#> Matrix products: default
#>   LAPACK version 3.12.1
#>
#> locale:
#> [1] LC_COLLATE=Spanish_Colombia.utf8  LC_CTYPE=Spanish_Colombia.utf8
#> [3] LC_MONETARY=Spanish_Colombia.utf8 LC_NUMERIC=C
#> [5] LC_TIME=Spanish_Colombia.utf8
#>
#> time zone: America/Bogota
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats     graphics  grDevices utils     datasets  methods   base
#>
#> other attached packages:
#> [1] knitr_1.52     ggplot2_4.0.3  pROC_1.19.1    sandwich_3.1-3 lmtest_0.9-40
#> [6] zoo_1.9-0      car_3.1-5      carData_3.0-6
#>
#> loaded via a namespace (and not attached):
#>  [1] Matrix_1.7-5       gtable_0.3.6       dplyr_1.2.1        compiler_4.6.1
#>  [5] tidyselect_1.2.1   Rcpp_1.1.2         splines_4.6.1      scales_1.4.0
```

```
#>  [9] yaml_2.3.12        fastmap_1.2.0      lattice_0.22-9     R6_2.6.1
#> [13] labeling_0.4.3     generics_0.1.4     Formula_1.2-6      tibble_3.3.1
#> [17] pillar_1.11.1      RColorBrewer_1.1-3 rlang_1.3.0        xfun_0.60
#> [21] S7_0.2.2           otel_0.2.0         cli_3.6.6          mgcv_1.9-4
#> [25] withr_3.0.3        magrittr_2.0.5     digest_0.6.39      grid_4.6.1
#> [29] rstudioapi_0.19.0  nlme_3.1-169       lifecycle_1.0.5    vctrs_0.7.3
#> [33] evaluate_1.0.5     glue_1.8.1         farver_2.1.2       stats4_4.6.1
#> [37] abind_1.4-8        rmarkdown_2.32     tools_4.6.1        pkgconfig_2.0.3
#> [41] htmltools_0.5.9
```